Лекция 1. Введение

Основы интеллектуального анализа данных

Полузёров Т. Д.

БГУ ФПМИ

Структура курса

1. О чем предмет
2. Основные обозначения
3. Примеры реальных задач
4. Особенности в данных и постановках задач

Data science - это всё про данные

Данные и информация в целом имеет огромную ценность. Сбор, хранение, обработка и анализ данных - целая наука включающая многие направления.

На основании данных можно:

- Принимать бизнес решения
- Находить зависимости
- Прогнозировать
- Автоматизировать процессы
- Генерировать синтетические объекты

Типы задач

Можно выделить основные две группы задач:

- Обучение с учителем:
  - Регрессия - прогноз численного значения
  - Классификация - определения класса объекта
  - Ранжирование - упорядочивание объектов
- Обучение без учителя:
  - Кластеризация - выделение семейств, групп в данных
  - Поиск ассоциативных правил - поиск зависимых событий
  - Понижение размерности - сжатие данных при разумной потере информации

Этапы решения задач

Классическая схема решения задачи состоит из этапов:

1. Определение задачи которую нужно решить
2. Сбор и подготовка данных
3. Определение используемых инструментов, моделей
4. **Построение модели**
5. **Первичная оценка качества модели (offline evaluation)**
6. Внедрение или доработка модели
7. Оценка результатов работы в продакшене (online evaluation)

Постановка задачи. Обучение с учителем

$\mathbb{X}$ - множество объектов
$\mathbb{Y}$ - множество ответов
$y^* : \mathbb{X} \to \mathbb{Y}$ -неизвестная зависимость (target function)

Дано:
$X = \{x_1, ..., x_\ell\} \subset \mathbb{X}$ - обучающая выборка (samples)
$Y = \{y_1, ..., y_\ell\} = \{y^*(x_i), i = 1...\ell\} \subset \mathbb{Y}$ - известные ответы (targets)

Необходимо:
Найти алгоритм (решающую функцию, модель) $a : \mathbb{X} \to \mathbb{Y}$
приближающую y^* **на всём** множестве $\mathbb{X}$

Признаковое описание объектов

$f_j : \mathbb{X} \to D_j, j = 1, ..., n$ - признаки объекта (features), измерение некоторох характеристик объекта
Вектор $(f_1(x), ..., f_n(x))$ - признаковое описание объекта x.
Матрица "объекты-признаки":

$$F = (f(x_{ij}))_{\ell \times n} = \begin{pmatrix} f_1(x_1) & ... & f_n(x_1) \\ ... & ... & ... \\ f_1(x_\ell) & ... & f_n(x_\ell) \end{pmatrix}$$

Далее будем отождествлять признаковое описание объекта с самим объектом:
$x := (f_1(x), ..., f_n(x))$, т.е. $F := X$

Типы признаков

Основные типы признаков:

- $D_j = \{0, 1\}$ - бинарный признак f_j
- $|D_j| < \infty$ и определена только операция сравнения на равенство - категориальный признакf_j
- $|D_j| < \infty$ f_j и определены операции сравнения больше, меньше, равенство - порядковый (ранговый) признак f_j
- $D_j \subseteq \mathbb{R}$ - количественный признак f_j

Примеры:

- Цвет - категориальный признак, нельзя сказать "Красный» "Синий"
- Офицерские звания - пример порядкового признака, можно ортировать категории
- Время/даты - может проявлять свойства непрерывных, категориальных, циклических типов

Форма множества ответов - определяет тип задачи

Задача классификации:

- $\mathbb{Y} = \{0, 1\}$ - бинарная классификация
- $\mathbb{Y} = \{1, ...M\}$ - на M непересекающихся классов (multiclass)
- $\mathbb{Y} = \{0, 1\}^M$ - на M классов, которые могут пересекаться (multilabel)

Восстановления регрессии:

- $\mathbb{Y} = \mathbb{R}$
- $\mathbb{Y} = \mathbb{R}^m$

В задачах "обучения без учителя" - множество $\mathbb{Y}$ не определено, отсутствует

Модель - как семейство параметризованных функций

Модель - параметрическое семейство функций

$$\mathbb{A} = \{a(x, \theta) | \theta \in \Theta\}$$

где $a : \mathbb{X} \times \Theta \to \mathbb{Y}$ - фиксированная функция, Θ - множество допустимых значений θ

Пример:

- $\{a(x) = \sum_{j=1}^{n} \omega_j x_j \ |\omega_j \in \mathbb{R}\}$ - семейство линейных моделей для задачи регрессии, $\mathbb{Y} = \mathbb{R}$
- $\{a(x) = [(\sum_{j=1}^{n} \omega_j x_j) > 0] | \omega_j \in \mathbb{R}\}$ - семейство линейных моделей для бинарной классификации, $\mathbb{Y} = 0, 1$

Метод обучения

Метод обучения (learning algorithm) - это отображение вида

$$\mu : (\mathbb{X} \times \mathbb{Y}) \to \mathbb{A}$$

которое произвольной конечной выборке $(X \times Y) = \{(x_i, y_i\}_{i=1}^{\ell}$ ставит в соответствие некоторый алгоритм $a \in \mathbb{A}$

Обучить или построить модель (fit) - значит с помощью метода обучения μ определить конкретные значения параметров для модели из выбранного семейства.

Функционалы качества

$\mathcal{L}(a, x)$ - функция потерь (loss function) - неотрицательная функция пропорциональная величине ошибки алгоритма $a \in \mathbb{A}$ на объекте $x \in \mathbb{X}$, если верный ответ есть y

Функции потерь для задач классификации:

- $\mathcal{L}(a, x) = [a(x) \neq y]$ - индикатор ошибки

Функции потерь для задач регрессии:

- $\mathcal{L}(a, x) = |a(x) - y|$ - абслолютное значение ошибки
- $\mathcal{L}(a, x) = (a(x) - y)^2$ - квадрат ошибки

Эмпирический риск - функционал качества алгоритма a на конечной выборке $X \subset \mathbb{X}$

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathcal{L}(a, x_i)$$

Основной метод обучения

Метод минимизации эмпирического риска:

$$\mu(X) = arg \min_{a \in A} Q(a, X)$$

Пример: метод наименьших квадратов $Y = \mathbb{R}, \mathcal{L}$ - квадратична

$$\mu(X) = arg \min_{a \in A} \sum_{i=1}^{\ell} (a(x_i, \theta) - y_i)^2$$

Два этапа модели:

- Этап обучения (fit): по имеющейся выборке X с помощью метода обучения μ построить a.
- Этап применения обученной модели (predict): $\hat{y}_i = a(x_i^{'})$

Обобщающая способность

Переобучение - одна из проблем машинного обучения

- **Из-за чего возникает переобучение?**
  избыточная сложность пространства параметров Θ, лишние степени свободы в модели $g(x, \theta)$ "тратятся"на чрезмерно точную подгонку под обучающую выборку. - переобучение есть всегда, когда есть оптимизация параметров по конечной (заведомо не полной) выборке.
- **Как обнаружить переобучение?**
  - эмпирически, путем разбиения выборки на train и test
- **Избавиться нельзя. Как минимизировать?**
  - минимизировать HoldOut, LOO или CV - наклыдвать ограничения на θ - регуляризация - минимизировать одну из теоретических оценок

Эмпирические оценки обобщающей способности

- Отложенная выборка (hold-out), $X = X_{train} \sqcup X_{test}$

$$HO(\mu, X_{train}, X_{test}) = Q(\mu(X_{train}, X_{test})) \to min$$

- Скользящий контроль (leave-one-out):

$$LOO(\mu, X) = \frac{1}{L} \sum_{i=1}^{L} Q(\mu(X \setminus \{x_i\}), x_i) \to min$$

- Кросс-проверка (cross-validation), $X = X_1 \sqcup X_2 \sqcup ... \sqcup X_k$

$$CV(\mu, X^L) = \frac{1}{k} \sum_{i=1}^{k} Q(\mu(X \setminus X_i), X_k) \to min$$

Кредитный скоринг

Объекты - заявки клиентов на кредит
Цель - одобрить или отклонить заявку
Признаки:

- Бинарные: пол, наличие авто, имеет ли действующие кредиты
- Непрерывные: зарплата, сумма кредита
- Порядковые: образование, должность
- Категориальные: тип кредита, семейный статус

Особенности задачи:

- Дисбаланс классов: очень мало дефолтных
- Неполные данные: разметка только ранее подписанных кредитов
- Требование оценки вероятности дефолта
- Интерпретируемость модели

Отток клиентов

Объекты - абонент в определенный момент времени
Цель - распознавать риск ухода клиента
Признаки:

- Бинарные: пол, подключался ли во время акций
- Непрерывные: месячный расход трафика, число подключенных функций
- Категориальные: источник привлечения клиента

Особенности задачи:

- Оценивание вероятностей
- Сверхбольшие выборки
- Сложность в формировании признакового описания объектов

Биометрическая идентификация

Объекты - образцы отпечатков пальцев
Цель - идентифицировать человека
Особенности задачи:

- Нетривиальное преобразование входных данных в информативные признаки
- Требование сверхвысокой точности

Оценка стоимости недвижимости

Объекты - описание объекта недвижимости
Цель - оценить стоимость
Признаки:

- Бинарные: комерческая ли, наличие балкона, лифта, мусоропровода
- Непрерывные: площадь, год постройки дома
- Категориальные: район города

Особенности задачи:

- Данные могут быть очень разнородной
- Стоимость меняется со временем: зависимость непостоянна
- Влияние внешних экономических факторов

Прогнозирование объемов продаж

Объекты - тройка (товар, магазин, день)
Цель - прогноз числа продаж

Особенности задачи:

- Разреженные данные
- Функция потерь сильно не симметрична

Ранжирование поисковой выдачи

Объекты - поисковой запрос
Цель - формирование выдачи по убыванию релевантности

Особенности задачи:

- Очень много данных,
- Требование быстрой обработки запросов
- Сложность формирования размеченной выборки

Частые проблемы в данных

- Разнородные -
- Неполные
- Неточные
- Противоречивые
- избыточные -
- Недостаточные
- Неструктурированные

Резюме

- Задача анализа данных - выявление зависимостей в данных
- Основные понятия: объект, ответ, признак, модель, функция потерь
- Модель - функция заданная с точностью до параметров. Обучить модель - найти оптимальный набор параметров
- Проблема описывается математически $\rightarrow$ сводится к задаче оптимизации $\rightarrow$ решается
- Грамотно сформулированная проблема + качественные данные = большая половина успеха