Лекция 1. Введение

Основы интеллектуального анализа данных

Полузёров Т. Д.

БГУ ФПМИ

Структура курса

1. О чем предмет
2. Основные обозначения
3. Примеры реальных задач

Data science - это про данные

Данные и информация в целом имеет огромную ценность. Сбор, хранение, обработка и анализ данных - целая наука включающая многие направления.

На основании данных можно:

- Принимать бизнес решения
- Находить зависимости
- Прогнозировать
- Автоматизировать процессы
- Генерировать синтетические объекты

Типы задач

Можно выделить основные две группы задач:

- Обучение с учителем:
  - Регрессия - оценка численного значения
  - Классификация - определения класса объекта
  - Ранжирование - упорядочивание объектов
- Обучение без учителя:
  - Кластеризация - выделение семейств, групп в данных
  - Поиск ассоциативных правил - поиск зависимых событий
  - Понижение размерности - сжатие данных при разумной потере информации

Этапы решения задач

Классическая схема решения задачи состоит из этапов:

1. Определение задачи которую нужно решить
2. Сбор и подготовка данных
3. Определение используемых инструментов, моделей
4. Построение модели
5. Первичная оценка качества модели (offline evaluation)
6. Внедрение или доработка модели
7. Оценка результатов работы в продакшене (online evaluation)

Постановка задачи. Обучение с учителем

X - множество объектов (objects)
Y - множество ответов (target)
$y : X \to Y$ -неизвестная зависимость (target function)

Дано:
$\{x_1, ..., x_\ell\} \subset X$ - обучающая выборка (samples)
$y_i = y(x_i), i = 1, ..., \ell$ - известные ответы (targets)

Необходимо:
Найти алгоритм (решающую функцию, модель) $a : X \to Y$ приближающую y на всем множестве X

Признаковое описание

$f_j : X \to D_j, j = 1, ..., n$ - признаки объекта (features)
Типы признаков:

- $D_j = \{0, 1\}$ - бинарный признак f_j
- $|D_j| < \infty$ - категориальный признак f_j
- $|D_j| < \infty$, причем порядок важен - порядковый признак f_j
- $D_j \subseteq \mathbb{R}$ - количественный признак f_j

Вектор $(f_1, ..., f_n(x))$ - признаковое описание объекта x.
Матрица "объекты-признаки":

$$F = (f(x_{ij}))_{n \times l} = \begin{pmatrix} f_{11} & ... & f_{1\ell} \\ ... & ... & ... \\ f_{n1} & ... & f_{n\ell} \end{pmatrix}$$

Типы задач

Задача классификации:

- $Y = \{-1, 1\}$ - бинарная классификация
- $Y = \{1, ...M\}$ - на M непересекающихся классов (multiclass)
- $Y = \{0, 1\}^M$ - на M классов, которые могут пересекаться (multilabel)

Восстановления регрессии:

- $Y = \mathbb{R}$ или $Y = \mathbb{R}^m$

Пару примеров задач

Модель

Модель - параметрическое семейство функций

$$A = \{g(x, \theta) | \theta \in \Theta\}$$

где $g : X \times \Theta \to Y$ - фиксированная функция, Θ - множество допустимых значений θ

Пример:
$g(x, \theta) = \sum_{j=1}^{n} \theta_j f_j(x)$ - линейная регрессия, $Y = \mathbb{R}$

$g(x, \theta) = sign(\sum_{j=1}^{n} \theta_j f_j(x))$ - классификация, $Y = \{-1, +1\}$

Метод обучения

Метод обучения (learning algorithm) - это отображение вида

$$\mu : (X \times Y)^{\ell} \to A$$

которое произвольной выборке $X^{\ell} = (x_i, y_i)_{i=1}^{\ell}$ ставит в соответствие некоторый алгоритм $a \in A$

Этап обучения и теста

Этап обучения (train):
Метод обучения μ строит по выборке $X^\ell = (x_i, y_i)_{i=1}^\ell$ алгоритм $a = \mu(X^\ell)$

$$\begin{pmatrix} f_1(x_1) & \dots & f_n(x_1) \\ \dots & \dots & \dots \\ f_1(x_\ell) & \dots & f_n(x_\ell) \end{pmatrix} \xrightarrow{\text{y}} \begin{pmatrix} y_1 \\ \dots \\ y_\ell \end{pmatrix}$$

Функционалы качества

$\mathcal{L}(a, x)$ - функция потерь (loss function) - величина ошибки алгоритма $a \in A$ на объекте $x \in X$

Функции потерь для задач классификации:

- $\mathcal{L}(a, x) = [a(x) \neq y(x)]$ - индикатор ошибки

Функции потерь для задач регрессии:

- $\mathcal{L}(a, x) = |a(x) - y(x)|$ - абслолютное значение ошибки
- $\mathcal{L}(a, x) = (a(x) - y(x))^2$ - квадрат ошибки

Эмпирический риск - функционал качества алгоритма a на X^ℓ

$$Q(a, X^\ell) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathcal{L}(a, x_i)$$

Основной метод обучения

Метод минимизации эмпирического риска:

$$\mu(X^\ell) = arg \min_{a \in A} Q(a, X^\ell)$$

Пример: метод наименьших квадратов $Y = \mathbb{R}, \mathcal{L} -$

$$\mu(X^\ell) = arg \min_{a \in A} \sum_{i=1}^{\ell} (g(x_i, \theta) - y_i)^2$$

Проблема обобщающей способности

- найдем ли мы "закон природы"или переобучимся, то есть подгоним функцию $g(x_i, \theta)$?
- будет ли $a = \mu(X^\ell)$ приближать функцию y на всем X?
- будет ли $Q(a, X^\ell)$ мало на новых данных - контрольной выборке $X^k = (x'_i, y'_i)_{i=1}^k, y'_i = y(x_i)$

content...

Переобучение - одна из проблем машинного обучения

- **Из-за чего возникает переобучение?**
  избыточная сложность пространства параметров Θ, лишние степени свободы в модели $g(x, \theta)$ "тратятся"на чрезмерно точную подгонку под обучающую выборку. - переобучение есть всегда, когда есть оптимизация параметров по конечной (заведомо не полной) выборке.
- **Как обнаружить переобучение?**
  - эмпирически, путем разбиения выборки на train и test
- **Избавиться нельзя. Как минимизировать?**
  - минимизировать HoldOut, LOO или CV - наклыдвать ограничения на θ - регуляризация - минимизировать одну из теоретических оценок

Эмпирические оценки обобщающей способности

- Эмпирический риск на тестовых данных (hold-out)

$$HO(\mu, X^\ell, X^k) = Q(\mu(X^\ell, X^k)) \to min$$

- Скользящий контроль (leave-one-out) $L = \ell + 1$:

$$LOO(\mu, X^L) = \frac{1}{L}\sum_{i=1}^{L} \mathcal{L}(\mu(X^L \setminus \{x_i\}), x_i) \to min$$

- Кросс-проверка (cross-validation), $L = \ell + k, X^L = X_n^\ell \sqcup X_n^k$:

$$CV(\mu, X^L) = \frac{1}{|N|}\sum_{n \in N} Q(\mu(X_n^\ell), X_n^k) \to min$$

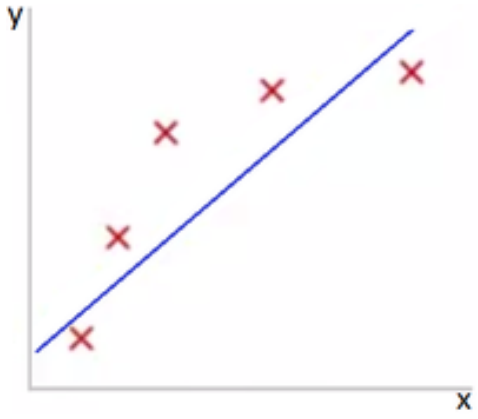
y
x