

## Лекция 2. Восстановление регрессии

### Основы интеллектуального анализа данных

Полузёров Т. Д.

БГУ ФПМИ

- 1 Постановка задачи
- 2 Градиентные методы
- 3 Регуляризация
- 4 Обобщение на нелинейный случай


## Постановка задачи регрессии

Пусть имеется выборка  $(X, y)_{i=1}^{\ell}$ , где  $X = (x_i)_{i=1}^{\ell} \subseteq \mathbb{X} = \mathbb{R}^{\ell \times n}$  - матрица признаков,  $y = (y_i)_{i=1}^{\ell} \subseteq \mathbb{Y} = \mathbb{R}^{\ell}$  - вектор целевых значений.


Между  $\mathbb{Y}$  и  $\mathbb{X}$  существует некоторая неизвестная зависимость  $y^* : \mathbb{X} \rightarrow \mathbb{Y}$

Задача регрессии состоит в том, чтобы по имеющимся данным  $(X, y)$  с помощью некоторой функции  $f(x, \theta)$ ,  $\theta \in \Theta$  приблизить  $y^*$  на всем множестве  $\mathbb{X}$ .

Simple linear model



Polynomial model



# Метод наименьших квадратов

Для решения такого рода задач применяется **метод наименьших квадратов (МНК)**:

$$Q(\theta, X) = \sum_{i=1}^{\ell} (f(x_i, \theta) - y_i)^2 \rightarrow \min_{\theta}$$

В случае дифференцируемости  $f$ , решение находится из уравнения:

$$\frac{\partial Q}{\partial \theta} = 2 \sum_{i=1}^{\ell} (f(x_i, \theta) - y_i) \frac{\partial f}{\partial \theta} = 0$$

## Линейная регрессия

Частный случай, когда  $f(x, \theta)$  линейна по своим параметрам -  
**линейная регрессия**

$$a(x) = \omega_0 + \sum_{j=1}^n \omega_j x_j = \omega_0 + \langle \omega, x \rangle$$

Определяется вектором коэффициентов  $\omega = (\omega_1, \dots, \omega_n) \in \mathbb{R}^n$  и свободным членом  $\omega_0 \in \mathbb{R}$

Для упрощения формул добавим к признаковому описанию объектов признак равный единице

$$x := (1, x_1, \dots, x_n), \omega = (\omega_0, \omega_1, \dots, \omega_n)$$

$$a(x) = \langle \omega, x \rangle$$

## МНК в случае линейной модели

- Модель регрессии - линейная,  $a(x) = \langle \omega, x \rangle$
- Функция потерь - квадратичная,  $\mathcal{L}(a, x_i) = (a(x_i) - y_i)^2$
- Метод обучения - минимизация среднего риска,  
$$Q(\omega) = \sum_{i=1}^{\ell} (a(x_i, \omega) - y_i)^2 \rightarrow \min_{\omega}$$

В матричном виде:

$$Q(\omega) = \frac{1}{\ell} \|X\omega - y\|^2 \rightarrow \min_{\omega}$$

## Точное аналитическое решение

Задача имеет точное аналитическое решение:

$$\omega = (X^T X)^{-1} X^T y$$

Недостатки аналитического решения:

- Обращение матрицы  $(X^T X)^{-1}$ : в случае плохо обусловленной матрицы веса неустойчивы и очень большие по модулю. Для вырожденной матрица - обращение невозможно.
- Вычислительная сложность -  $O(n^2 \ell + n^3)$

## Численное решение

Наиболее простой и подходящий класс методов –  
**градиентные методы оптимизации.**

Общая схема:

$$Q(\omega) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathcal{L}_i(\omega) \rightarrow \min_{\omega}$$


$$\omega^{(t+1)} = \omega^{(t)} - \alpha \cdot \nabla_{\omega} Q(\omega^{(t)})$$

где  $\alpha \in \mathbb{R}$

- некоторый параметр (размер шага)

Градиент квадратичного функционала:

$$\nabla_{\omega} Q = \frac{2}{\ell} X^T (X\omega - y)$$





# Метод градиентного спуска

---

## Algorithm 1 Метод градиентного спуска

---

**Input:**  $\alpha$  - градиентный шаг (темп обучения)

**Output:**  $\omega^*$  - оптимум функционала  $Q(\omega)$

**begin**

    Инициализировать  $\omega^{(0)}$

**while** не выполнен критерий остановки **do**

        вычислить градиент в точке

$$\nabla Q(\omega)|_{\omega=\omega^{(t)}} = \left( \frac{\partial Q(\omega)}{\partial \omega} \right)_{i=1}^n$$

        сделать шаг в сторону антиградиента

$$\omega^{(t+1)} = \omega^{(t)} - \alpha \cdot \nabla_{\omega} Q(\omega^{(t)})$$

**end**

**end**

---

## Идея ускорения алгоритма

Градиент  $\nabla Q(\omega)$  представим в виде суммы градиентов:

$$\nabla Q(\omega) = \frac{1}{\ell} \sum_{i=1}^{\ell} \nabla \mathcal{L}(\omega)$$

Идея состоит в том, чтобы вычислять не точное значение градиента по всей выборке  $X$ , а оценить по некоторой подвыборке  $X' \subset X$ ,  $|X'| = k \ll \ell$  небольшого размера.

$$\nabla Q(\omega) \approx \frac{1}{k} \sum_{i=1}^k \nabla \mathcal{L}(\omega)$$

# Метод стохастического градиента

---

## Algorithm 2 Метод стохастического градиента

---

**Input:**  $k$  - размер подвыборки,  $\alpha$  - градиентный шаг

**Output:**  $\omega^*$  - оптимум функционала  $Q(\omega)$

**begin**

Инициализировать  $\omega^{(0)}$

**while** не выполнен критерий остановки **do**

    выбрать набор  $X'$ ,  $|X'| = k$

    вычислить градиент в точке по подвыборке  $X'$

$$\nabla Q(\omega)|_{\omega=\omega^{(t)}} = \left( \frac{\partial Q(\omega)}{\partial \omega} \right)_{i=1}^n$$

    сделать шаг в сторону антиградиента

$$\omega^{(t+1)} = \omega^{(t)} - \alpha \cdot \nabla_{\omega} Q(\omega^{(t)})$$

**end**

**end**

## Другие популярные градиентные методы

## Другие популярные градиентные методы

## Другие популярные градиентные методы